

LAPORAN STUDI KASUS BUSINESS INTELLIGENCE



PEMBUATAN DATA WAREHOUSE DENGAN TEMA DATA GEMPA BUMI

(SasimokGuard — Seismic Activity Data Warehouse)

Dosen Pengampu:

Dr. Akhmad Irsyad, S.T., M.Kom.

Disusun Oleh:

Nama	NIM
Dharma Pala Candra	2409116065
Satria Rajawali E.A.	2409116067
Ghendinda Gantari Ayari	2409116080
Prakarsa Wira Mukti	240911

**PROGRAM STUDI SISTEM INFORMASI
FAKULTAS TEKNIK
UNIVERSITAS MULAWARMAN
2025**

KATA PENGANTAR

Puji syukur kehadiran Tuhan Yang Maha Esa atas segala rahmat, karunia, dan hidayah-Nya sehingga penulis dapat menyelesaikan laporan studi kasus mata kuliah Business Intelligence yang berjudul “Pembuatan Data Warehouse dengan Tema Data Gempa Bumi (SasimokGuard — Seismic Activity Data Warehouse)” dengan baik dan tepat waktu.

Laporan ini disusun sebagai bentuk implementasi konsep-konsep Business Intelligence dalam studi kasus nyata yang berkaitan dengan pengelolaan data kebencanaan, khususnya data gempa bumi di Indonesia. Melalui proyek SasimokGuard, penulis berupaya merancang dan mengimplementasikan sistem Data Warehouse yang mampu mengintegrasikan data seismik historis dan real-time dari berbagai sumber, mengolahnya melalui proses ETL (Extract, Transform, Load), serta menyajikannya dalam bentuk informasi yang dapat mendukung proses analisis dan pengambilan keputusan.

Dalam pengembangannya, proyek ini menerapkan berbagai konsep penting dalam bidang Business Intelligence dan Data Engineering, seperti Medallion Architecture, Star Schema, Data Warehouse, serta integrasi Geographic Information System (GIS). Penerapan konsep-konsep tersebut diharapkan mampu menghasilkan data yang terstruktur, berkualitas, dan siap digunakan untuk kebutuhan analisis aktivitas seismik, identifikasi pola kejadian gempa, serta mendukung upaya mitigasi bencana berbasis data.

Penulis menyadari bahwa laporan ini masih memiliki berbagai keterbatasan, baik dari sisi implementasi maupun penyajian materi. Oleh karena itu, kritik dan saran yang membangun sangat diharapkan guna penyempurnaan laporan serta pengembangan penelitian di masa mendatang.

Akhir kata, penulis mengucapkan terima kasih kepada semua pihak yang telah memberikan dukungan, bantuan, dan bimbingan selama proses penyusunan laporan ini, khususnya kepada Bapak Dr. Akhmad Irsyad, S.T., M.Kom. selaku dosen pengampu

mata kuliah Business Intelligence. Semoga laporan ini dapat memberikan manfaat serta menjadi referensi yang berguna bagi pembaca dalam memahami penerapan Business Intelligence, Data Warehouse, dan sistem analitik data kebencanaan.

DAFTAR ISI

KATA PENGANTAR.....	2
DAFTAR ISI.....	4
DAFTAR GAMBAR.....	6
BAB I PENDAHULUAN.....	7
1.1 Latar Belakang	7
1.2 Rumusan Masalah.....	8
1.3 Tujuan	9
1.4 Manfaat	9
BAB II TINJAUAN PUSTAKA	11
2.1 Data Warehouse	11
2.2 Medallion Architecture	12
a. Bronze Layer (Raw Data)	12
b. Silver Layer (Cleaned & Validated)	13
c. Gold Layer (Curated & Presentation)	13
2.3 ETL (Extract, Transform, Load)	13
2.4 Star Schema	15
BAB III TAHAPAN PROSES DAN IMPLEMENTASI ETL.....	18
3.1 Gambaran Umum Tahapan Proses.....	18
3.2 Arsitektur Sistem SasimokGuard (Pendekatan Dual-Pipeline)	18
3.3 Implementasi Pipeline ETL	19
A. Pipeline 1: Historical Data Preparation (Google Colab 1 - Kaggle/BMKG CSV)	19
B. Pipeline 2: Live ETL Pipeline (Google Colab 2 — API BMKG, USGS, EMSC)	20
3.4 Implementasi Medalion Architecture	22
A. Bronze Layer (Raw Data)	22
B. Silver Layer (Cleaned & Validated).....	22
C. Gold Layer (Curated & Presentation)	23
3.5 Pemodelan Dimensional (Star Schema).....	23
A. Tabel Fakta — fact_gempa	23
B. Tabel Dimensi	24
BAB IV ANALISIS DATA DAN BUSINESS INTELLIGENCE.....	25
4.1 Analisis Distribusi Magnitudo	25

4.2 Analisis Tren Aktivitas Seismik	26
4.3 Analisis Frekuensi Kejadian Berdasarkan Wilayah.....	26
4.4 Analisis Hubungan Kedalaman (Depth) dan Magnitudo	27
4.5 Komparasi Volume Data Berdasarkan Sumber Pencatat.....	28
BAB V PENUTUP.....	30
5.1 Kesimpulan	30
5.2 Saran	31
LAMPIRAN.....	33

DAFTAR GAMBAR

Gambar 1.1 <i>Gempa Bumi 2021</i>	7
Gambar 2.1 <i>Data Warehouse</i>	11
Gambar 2.2 <i>Medallion Architecture</i>	12
Gambar 2.3 <i>ETL</i>	13
Gambar 2.4 <i>Star Schema</i>	15

BAB I

PENDAHULUAN

1.1 Latar Belakang

Indonesia merupakan salah satu negara dengan tingkat aktivitas seismik tertinggi di dunia. Posisi geografis Indonesia yang berada di antara tiga lempeng tektonik utama — Lempeng Indo-Australia, Lempeng Eurasia, dan Lempeng Pasifik — menjadikan negara ini sangat rentan terhadap kejadian gempa bumi. Berdasarkan data historis, Indonesia mencatatkan ribuan kejadian gempa per tahun dengan berbagai skala magnitudo, mulai dari getaran kecil yang tidak dirasakan hingga gempa destruktif yang menimbulkan korban jiwa dan kerusakan infrastruktur masif.



Gambar 1.1 *Gempa Bumi 2021*

Sumber: <https://geologi.esdm.go.id/media-center/gempa-bumi-merusak-di-indonesia-tahun-2021>

Fenomena gempa bumi tidak hanya berdampak pada kerugian material, tetapi juga memberikan tekanan psikologis dan sosial bagi masyarakat. Tragedi gempa Aceh 2004, Yogyakarta 2006, Palu-Donggala 2018, serta Cianjur 2022 merupakan contoh nyata betapa pentingnya sistem pemantauan dan analisis data seismik yang cepat, akurat, dan komprehensif. Keterlambatan informasi atau kualitas data yang rendah dapat memperburuk respons bencana secara signifikan.

Di sisi lain, perkembangan teknologi informasi membuka peluang besar untuk membangun sistem pemantauan berbasis data yang canggih. Badan Meteorologi,

Klimatologi, dan Geofisika (BMKG) selaku otoritas resmi pemerintah Indonesia telah menyediakan Application Programming Interface (API) publik yang memungkinkan akses data gempa bumi secara real-time. Sumber data internasional seperti United States Geological Survey (USGS) dan European-Mediterranean Seismological Centre (EMSC) juga menyediakan data seismik global yang dapat dimanfaatkan sebagai referensi pembandingan.

Namun demikian, data gempa bumi yang tersedia dari berbagai sumber tersebut seringkali bersifat heterogen — berbeda dalam format, struktur, satuan, dan tingkat kelengkapan. Tantangan nyata yang dihadapi dalam pemanfaatan data ini adalah bagaimana mengintegrasikan, membersihkan, dan mengelola data dari berbagai sumber tersebut menjadi satu repositori terpadu yang andal dan siap dianalisis. Proses integrasi ini membutuhkan pendekatan rekayasa data yang terstruktur dan sistematis.

SasimokGuard hadir sebagai solusi atas permasalahan tersebut. SasimokGuard adalah sistem data warehouse berbasis dual-pipeline yang dirancang untuk mengumpulkan, memproses, dan menganalisis data seismik dari sumber historis (Kaggle/BMKG CSV) maupun sumber real-time (API BMKG, USGS, EMSC). Dengan menerapkan Medallion Architecture dan pemodelan dimensional berbasis Star Schema, SasimokGuard mampu menyajikan wawasan bisnis (business intelligence) yang komprehensif terkait pola, tren, dan distribusi kejadian gempa bumi di Indonesia dan sekitarnya.

1.2 Rumusan Masalah

Berdasarkan latar belakang yang telah diuraikan, rumusan masalah dalam proyek ini adalah sebagai berikut:

1. Bagaimana merancang dan mengimplementasikan sistem data warehouse yang mampu mengintegrasikan data seismik dari sumber historis (Kaggle/BMKG CSV) dan sumber real-time (API BMKG, USGS, EMSC) secara terpadu?
2. Bagaimana merancang pipeline ETL (Extract, Transform, Load) yang efisien untuk menangani heterogenitas format data dari berbagai sumber tersebut?

3. Bagaimana menerapkan Medallion Architecture (Bronze, Silver, Gold) untuk memastikan kualitas dan konsistensi data di setiap tahapan pemrosesan?
4. Bagaimana memodelkan data seismik ke dalam skema dimensional (Star Schema) yang optimal untuk keperluan analisis Business Intelligence?
5. Pola dan tren apa saja yang dapat ditemukan dari analisis data seismik yang telah dikurasi melalui sistem SasimokGuard?

1.3 Tujuan

Proyek SasimokGuard bertujuan untuk:

- Membangun sistem data warehouse terintegrasi yang menggabungkan data seismik historis dan real-time dari berbagai sumber terpercaya.
- Mengimplementasikan pipeline ETL dual-pipeline menggunakan Python (Pandas) dan SQL untuk proses ekstraksi, transformasi, dan pemuatan data secara otomatis dan terstruktur.
- Menerapkan Medallion Architecture tiga lapis (Bronze, Silver, Gold) untuk menjamin kualitas, konsistensi, dan keterlacakan data.
- Membangun model dimensional berbasis Star Schema yang terdiri dari tabel fakta (fact_gempa) dan tabel dimensi (dim_waktu, dim_lokasi, dim_sumber).
- Melakukan analisis Business Intelligence mendalam terhadap data seismik untuk mengidentifikasi pola distribusi magnitudo, tren aktivitas, konsentrasi wilayah, korelasi kedalaman-magnitudo, dan perbandingan sumber data.

1.4 Manfaat

Proyek ini memberikan manfaat pada berbagai dimensi, antara lain:

A. Manfaat Akademis

- Memberikan pemahaman praktis tentang perancangan dan implementasi data warehouse modern dalam domain bencana alam.

- Mendemonstrasikan penerapan konsep ETL, Medallion Architecture, dan Star Schema pada kasus nyata yang relevan.
- Menjadi referensi bagi penelitian selanjutnya dalam bidang rekayasa data seismik di Indonesia.

B. Manfaat Teknis

- Menghasilkan repositori data seismik terkurasi berkualitas tinggi yang siap digunakan untuk analisis lanjutan.
- Menyediakan arsitektur data yang modular, skalabel, dan dapat dikembangkan lebih lanjut.
- Membangun pipeline data otomatis yang meminimalkan intervensi manual dalam proses pembaruan data.


C. Manfaat Sosial

- Mendukung upaya peningkatan kesadaran masyarakat dan pemangku kepentingan terhadap potensi risiko seismik di wilayah Indonesia.
- Menyediakan fondasi analitik bagi lembaga penanggulangan bencana (BPBD) dalam perencanaan respons dan mitigasi bencana berbasis data.

BAB II

TINJAUAN PUSTAKA

2.1 Data Warehouse



Gambar 2.1 *Data Warehouse*

Sumber: <https://www.adjust.com/glossary/data-warehouse/>

Data Warehouse adalah sistem repositori data terpusat yang dirancang untuk mengumpulkan, mengintegrasikan, dan mengelola data dari berbagai sumber heterogen dengan tujuan utama mendukung analitik bisnis dan pengambilan keputusan. Inmon (1992), yang dikenal sebagai "Bapak Data Warehouse", mendefinisikannya sebagai sebuah koleksi data yang subject-oriented, integrated, time-variant, dan non-volatile.


Keempat karakteristik utama Data Warehouse menurut Inmon dapat dijabarkan sebagai berikut:

- **Subject-Oriented:** Data diorganisasikan berdasarkan subjek atau domain bisnis tertentu (misalnya aktivitas gempa bumi), bukan berdasarkan proses transaksi operasional.
- **Integrated:** Data yang berasal dari berbagai sumber dengan format dan standar yang berbeda-beda disatukan ke dalam satu representasi yang konsisten dan seragam.
- **Time-Variant:** Data Warehouse menyimpan data historis dalam jangka waktu yang panjang, memungkinkan analisis tren dan perbandingan lintas periode waktu.

- **Non-Volatile:** Data yang sudah tersimpan di Data Warehouse bersifat stabil dan tidak dimodifikasi atau dihapus oleh proses operasional harian.

Dalam ekosistem SasimokGuard, Data Warehouse berfungsi sebagai fondasi tunggal yang mengintegrasikan tiga sumber data utama: data sensor seismik dari jaringan BMKG, data demografis dan kependudukan dari BPS, serta laporan kerusakan lapangan dari BPBD. Integrasi ini menghilangkan silo data yang selama ini menjadi hambatan utama dalam pengambilan keputusan mitigasi bencana yang cepat dan akurat.

2.2 Medallion Architecture



Gambar 2.2 Medallion Architecture

Sumber: <https://www.databricks.com/blog/what-is-medallion-architecture>

Medallion Architecture adalah pola desain Data Warehouse modern yang mengorganisasikan alur pemrosesan data ke dalam tiga lapisan logis yang berjenjang: Bronze, Silver, dan Gold. Arsitektur ini dipopulerkan oleh Databricks sebagai bagian dari paradigma Lakehouse Architecture dan telah menjadi standar industri yang diadopsi secara luas dalam implementasi data engineering kontemporer, terutama untuk mengelola data dalam skala besar dengan tingkat keandalan tinggi.

Setiap lapisan dalam Medallion Architecture memiliki peran dan karakteristik yang distingtif:

a. Bronze Layer (Raw Data)

Lapisan Bronze merupakan zona pendaratan pertama (landing zone) di mana data dari sumber eksternal disimpan secara verbatim tanpa modifikasi apapun. Pada lapisan ini, seluruh data disimpan dalam tipe data TEXT untuk mempertahankan fleksibilitas dan

menghindari hilangnya informasi akibat konversi tipe data yang prematur. Prinsip fundamental lapisan ini adalah "simpan dulu, proses belakangan," sehingga lapisan Bronze berfungsi sekaligus sebagai audit trail yang memungkinkan rekonstruksi data jika terjadi kesalahan logika di lapisan yang lebih tinggi.


b. Silver Layer (Cleaned & Validated)

Lapisan Silver adalah tahap pembersihan dan validasi data di mana data Bronze diolah menjadi data yang dapat dipercaya. Proses yang berlangsung pada lapisan ini mencakup: penghapusan data duplikat (deduplication), penanganan nilai yang hilang (missing values imputation), konversi tipe data (type casting) dari teks ke format DATE, DECIMAL, dan INT yang tepat, serta standarisasi format dan nilai. Data pada lapisan Silver telah memenuhi standar kualitas minimum namun belum dioptimalkan untuk konsumsi analitik.

c. Gold Layer (Curated & Presentation)

Lapisan Gold adalah lapisan final yang sepenuhnya siap dikonsumsi oleh aplikasi akhir, termasuk dashboard BI, sistem DSS, dan API publik. Data pada lapisan ini disusun menggunakan desain Star Schema yang dioptimalkan untuk performa query analitik yang tinggi. Denormalisasi tabel dimensi memungkinkan eksekusi query agregasi yang kompleks tanpa memerlukan kalkulasi berulang, sehingga secara signifikan meningkatkan kecepatan respons dashboard.

2.3 ETL (Extract, Transform, Load)



Gambar 2.3 *ETL*

Sumber: <https://www.binar.co.id/blog/etl-adalah>


ETL adalah proses tiga tahap yang merupakan fondasi fundamental dalam pembangunan dan pemeliharaan setiap Data Warehouse. Proses ini bertanggung jawab untuk memindahkan data dari sistem sumber (source systems) ke repositori target (Data Warehouse) sambil memastikan kualitas dan konsistensi data terjaga sepanjang perjalanannya.

Tiga tahapan proses ETL dapat dijabarkan sebagai berikut:

- **Extract (Ekstraksi):** Tahap pengambilan data mentah dari berbagai sumber heterogen, yang dalam konteks SasimokGuard mencakup file CSV dari katalog BMKG/Kaggle, API laporan cuaca dan geografi, serta database kependudukan BPS. Pada tahap ini, data diambil apa adanya tanpa transformasi.
- **Transform (Transformasi):** Tahap inti ETL yang melibatkan serangkaian operasi pembersihan dan pengayaan data. Operasi ini mencakup penghapusan kolom yang tidak relevan, penanganan missing values, standarisasi format tanggal dari "YYYY/MM/DD" ke format DATE standar, validasi koordinat geografis, serta feature engineering seperti penambahan kolom klasifikasi status gempa berdasarkan ambang batas magnitudo.
- **Load (Pemuatan):** Tahap akhir di mana data yang telah ditransformasi dimuat ke dalam tabel target di Data Warehouse. Dalam SasimokGuard, proses load dilakukan secara bertahap: dari sumber CSV ke Bronze, dari Bronze ke Silver melalui SQL transformation, dan dari Silver ke Gold melalui operasi JOIN dan ekstraksi nilai DISTINCT untuk mengisi tabel dimensi dan fakta.

Implementasi ETL dalam proyek SasimokGuard menggunakan pendekatan dua tahap: tahap pertama memanfaatkan Python Pandas di lingkungan Jupyter Notebook/Google Colab untuk data cleaning awal dan feature engineering, menghasilkan file `katalog_gempa_downloadable.csv` sebagai output. Tahap kedua dilakukan sepenuhnya dalam SQL di lingkungan PostgreSQL via Supabase, membangun alur transformasi dari Bronze hingga Gold melalui script DDL yang terstruktur.

2.4 Star Schema



Gambar 2.4 *Star Schema*

Sumber: <https://medium.com/analysts-corner/in-depth-guide-to-star-schema-in-data-warehouse-modeling-concepts-design-principles-and-f540f3c4744b>

Konsep dan Arsitektur *Star Schema*

1. Definisi *Star Schema*

Star Schema (Skema Bintang) adalah salah satu model arsitektur data dua dimensi yang paling umum digunakan dalam perancangan *Data Warehouse* dan *Business Intelligence* (BI). Dinamakan demikian karena bentuk diagram relasionalnya menyerupai bintang, di mana terdapat satu tabel pusat yang dikelilingi oleh beberapa tabel pendukung. Pendekatan pemodelan ini dirancang khusus untuk mengoptimalkan kinerja kueri pada sistem *Online Analytical Processing* (OLAP) dan mempermudah analisis data dalam jumlah besar.

2. Komponen Utama

Arsitektur *Star Schema* secara fundamental terdiri dari dua jenis tabel utama:

- **Tabel Fakta (*Fact Table*):**

Tabel ini berada di pusat skema dan berfungsi untuk menyimpan data kuantitatif atau *metrics* (ukuran) yang dapat dihitung, seperti jumlah penjualan, pendapatan, atau durasi transaksi. Selain itu, Tabel Fakta juga memuat *Foreign Key* (kunci tamu) yang

menghubungkannya secara langsung ke setiap Tabel Dimensi. Tabel ini biasanya memiliki jumlah baris (rekaman) yang sangat besar namun jumlah kolom yang relatif sedikit.

- **Tabel Dimensi (*Dimension Tables*):**

Tabel-tabel ini mengelilingi Tabel Fakta dan berfungsi untuk menyimpan atribut deskriptif yang memberikan konteks pada data di Tabel Fakta. Contohnya adalah dimensi Waktu (*Time*), Produk (*Product*), Pelanggan (*Customer*), atau Lokasi (*Location*). Tabel Dimensi bersifat denormalisasi, yang berarti data tidak dipecah menjadi beberapa tabel relasional yang lebih kecil, sehingga menghasilkan jumlah kolom (atribut) yang banyak untuk mendeskripsikan suatu entitas secara komprehensif.

3. Keunggulan Implementasi

Penerapan *Star Schema* dalam perancangan *data pipeline* menawarkan beberapa keuntungan strategis, antara lain:

- **Kinerja Kueri yang Optimal:** Karena struktur dimensinya didenormalisasi, sistem tidak perlu melakukan proses *JOIN* yang rumit dan berlapis-lapis antar tabel. Hal ini secara signifikan mempercepat waktu respons kueri (*query performance*), terutama saat melakukan agregasi data untuk *dashboard* BI.
- **Kesederhanaan Desain:** Struktur yang sederhana membuatnya jauh lebih mudah dipahami oleh analis data maupun pengguna bisnis, sehingga proses navigasi data dan pembuatan laporan menjadi lebih intuitif.
- **Dukungan Agregasi Data:** Model ini sangat efektif untuk menjalankan fungsi agregasi bawaan seperti SUM, COUNT, dan AVERAGE, yang merupakan operasi inti dalam analitik data.

4. Keterbatasan

Meskipun memiliki kinerja pembacaan data yang tinggi, *Star Schema* memiliki keterbatasan pada sisi redundansi data. Denormalisasi pada Tabel Dimensi menyebabkan beberapa data teks atau deskriptif disimpan secara berulang. Hal ini dapat

meningkatkan kebutuhan kapasitas penyimpanan (*storage*) dan memerlukan perhatian khusus saat melakukan pembaruan data (*update*) agar integritas data tetap terjaga.

Penjelasan di atas sudah mencakup struktur dasar, komponen, hingga evaluasi kelebihan dan kekurangannya, sehingga sangat cocok untuk dimasukkan ke dalam bab tinjauan pustaka, landasan teori, atau dokumentasi arsitektur proyek sistem informasi.

BAB III

TAHAPAN PROSES DAN IMPLEMENTASI ETL

3.1 Gambaran Umum Tahapan Proses

Pengembangan sistem data warehouse SasimokGuard dilaksanakan melalui enam tahapan utama yang saling berkesinambungan, mulai dari identifikasi kebutuhan hingga penyajian hasil analisis Business Intelligence:

- 1 Identifikasi Sumber Data: Penentuan sumber data yang akan diintegrasikan (Kaggle CSV, API BMKG, API USGS, API EMSC) beserta karakteristik format dan frekuensi pembaruannya.
- 2 Perancangan Arsitektur: Desain arsitektur sistem secara menyeluruh, meliputi alur dual-pipeline, struktur Medallion Architecture, dan model dimensional Star Schema.
- 3 Implementasi Pipeline ETL: Pembangunan pipeline ETL menggunakan Python (Pandas, Requests) di lingkungan Google Colab untuk masing-masing pipeline (historis dan real-time).
- 4 Pembuatan Database dan Skema: Pembuatan struktur database di MySQL/PostgreSQL beserta DDL untuk tabel Bronze, Silver, Gold, tabel fakta, dan tabel dimensi.
- 5 Pengujian dan Validasi: Pengujian fungsionalitas setiap komponen pipeline, validasi kualitas data, dan verifikasi konsistensi skema.
- 6 Analisis Data dan Business Intelligence: Eksekusi query analitik pada lapisan Gold untuk menghasilkan wawasan bisnis yang bermakna dari data seismik yang telah dikurasi.

3.2 Arsitektur Sistem SasimokGuard (Pendekatan Dual-Pipeline)

Arsitektur SasimokGuard dibangun di atas pendekatan Dual-Pipeline yang secara fundamental memisahkan alur pemrosesan data historis dan data real-time. Pemisahan

ini dipilih karena kedua kategori data memiliki karakteristik yang berbeda secara signifikan dalam hal format sumber, frekuensi pembaruan, dan volume data yang ditangani.

Aspek	Pipeline 1: Historical	Pipeline 2: Live/Real-Time
Sumber Data	Kaggle Dataset CSV, BMKG CSV historis	API BMKG, API USGS, API EMSC
Frekuensi Eksekusi	Sekali (inisialisasi) / berkala	Periodik / on-demand
Volume Data	Puluhan ribu – jutaan record	Ratusan record per eksekusi
Format Input	CSV flat files	JSON via HTTP REST API
Strategi Load	Full Load (inisialisasi)	Incremental Load (upsert)
Tools Utama	pandas.read_csv(), SQLAlchemy	requests.get(), json.loads()
Colab Notebook	Google Colab 1	Google Colab 2

Kedua pipeline bermuara pada target yang sama: lapisan Medallion Architecture di dalam database MySQL/PostgreSQL, dan selanjutnya data dari lapisan Gold dikonsumsi untuk keperluan analisis Business Intelligence.

3.3 Implementasi Pipeline ETL

A. Pipeline 1: Historical Data Preparation (Google Colab 1 - Kaggle/BMKG CSV)

Pipeline pertama menangani pemrosesan data seismik historis yang bersumber dari dataset Kaggle dan file CSV repository BMKG. Data ini mencakup catatan kejadian gempa bumi dalam rentang waktu beberapa dekade terakhir dan menjadi fondasi utama analisis tren jangka panjang.

Tahap Extract — Pipeline 1

Proses ekstraksi pada Pipeline 1 dimulai dengan pengunduhan dataset Kaggle menggunakan Kaggle API (kaggle datasets download) langsung dari lingkungan Google Colab. File CSV yang diperoleh kemudian dimuat ke dalam DataFrame Pandas dengan konfigurasi berikut:

- Penentuan encoding (UTF-8 atau latin-1 sesuai sumber).

- Pemilihan kolom yang relevan: tanggal, waktu, latitude, longitude, kedalaman (depth), magnitudo, dan wilayah.
- Pembacaan metadata sumber untuk keperluan auditing di lapisan Bronze.

Tahap Transform — Pipeline 1

Setelah ekstraksi, data mentah melalui serangkaian transformasi komprehensif menggunakan Pandas:

- Standarisasi nama kolom ke format snake_case yang konsisten.
- Parsing kolom tanggal dan waktu ke tipe datetime64 dengan zona waktu UTC.
- Konversi kolom numerik (latitude, longitude, depth, magnitude) ke tipe float64.
- Penanganan missing values: baris dengan magnitudo atau koordinat null dihapus; nilai depth null diimputasi dengan median.
- Penghapusan duplikat berdasarkan kombinasi kunci komposit (tanggal, latitude, longitude, magnitudo) dengan toleransi 0.01 derajat koordinat.
- Validasi domain: filter magnitudo dalam rentang 0–10 dan depth > 0 km.
- Penambahan kolom metadata: `source_name = 'KAGGLE_BMKG_HISTORICAL', load_timestamp = datetime.utcnow().`

Tahap Load — Pipeline 1

Data yang telah ditransformasi dimuat ke dalam database melalui dua tahap: pertama ke tabel `bronze_gempa_raw` sebagai arsip data mentah, kemudian ke tabel `silver_gempa_clean` setelah proses validasi. Pemuatan menggunakan SQLAlchemy dengan parameter `if_exists='append'` untuk tabel Bronze (append-only) dan strategi DELETE-INSERT berdasarkan `source_name` untuk re-load yang idempotent.

B. Pipeline 2: Live ETL Pipeline (Google Colab 2 — API BMKG, USGS, EMSC)

Pipeline kedua dirancang untuk mengambil data seismik terkini dari tiga sumber API internasional: BMKG (Indonesia), USGS (Amerika Serikat), dan EMSC (Eropa-Mediterrania). Penggunaan tiga sumber API sekaligus memberikan redundansi dan memungkinkan validasi silang data antar lembaga pencatat gempa.

Sumber API yang Digunakan

Sumber	Endpoint	Format	Cakupan Wilayah
BMKG	https://data.bmkg.go.id/DataMKG/TEWS/gempadirasakan.json	JSON	Indonesia & sekitarnya
USGS	https://earthquake.usgs.gov/earthquakes/feed/v1.0/summary/all_hour.geojson	GeoJSON	Global (difilter wilayah Indonesia)
EMSC	https://www.seismicportal.eu/fdsnws/event/1/query?limit=10&format=json	JSON	Global

Tahap Extract — Pipeline 2

Setiap sumber API dipanggil menggunakan library requests dengan mekanisme retry exponential backoff (maksimal 3 percobaan) untuk menangani kondisi jaringan yang tidak stabil. Parameter query untuk USGS mencakup filter geografis (latitude -11 hingga 6, longitude 95 hingga 141) dan filter magnitudo minimum (≥ 1.0) untuk membatasi data pada wilayah Indonesia dan sekitarnya.

Tahap Transform — Pipeline 2

Karena setiap API memiliki struktur respons yang berbeda, setiap sumber memiliki fungsi parser khusus yang menormalisasi output ke skema kolom yang seragam. Transformasi mencakup:

- Ekstraksi field dari nested JSON (khususnya untuk format GeoJSON USGS).
- Konversi waktu kejadian dari berbagai format string ke datetime UTC yang seragam.
- Normalisasi satuan kedalaman (km) dan penambahan atribut `source_name` per rekaman.
- Deduplikasi lintas-sumber menggunakan proximity check — dua kejadian dianggap duplikat jika perbedaan waktu < 60 detik, jarak koordinat < 0.5 derajat, dan magnitudo berbeda < 0.3 .

Tahap Load — Pipeline 2

Pipeline kedua menggunakan strategi incremental load dengan mekanisme upsert (INSERT ... ON DUPLICATE KEY UPDATE di MySQL). Kunci unik ditentukan berdasarkan kombinasi waktu_utc, latitude (presisi 3 desimal), longitude (presisi 3 desimal), dan source_name untuk mencegah duplikasi antar eksekusi pipeline yang berurutan.

3.4 Implementasi Medallion Architecture

A. Bronze Layer (Raw Data)

Lapisan Bronze berfungsi sebagai landing zone atau staging area yang menyimpan data dalam format paling mendekati kondisi aslinya. Prinsip utama Bronze Layer adalah append-only — tidak ada penghapusan atau modifikasi data, hanya penambahan. Ini memastikan bahwa raw data selalu tersedia untuk keperluan debugging, audit, dan re-processing jika diperlukan.

Struktur tabel Bronze dalam SasimokGuard:

Nama Kolom	Tipe Data	Keterangan
id_bronze	BIGINT AUTO_INCREMENT	Primary key surrogate
raw_datetime_str	VARCHAR(100)	Datetime asli dari sumber (belum diparse)
raw_latitude	VARCHAR(50)	Latitude mentah dari sumber
raw_longitude	VARCHAR(50)	Longitude mentah dari sumber
raw_depth	VARCHAR(50)	Kedalaman mentah
raw_magnitude	VARCHAR(50)	Magnitudo mentah
raw_region	TEXT	Deskripsi wilayah dari sumber
source_name	VARCHAR(100)	Nama sumber data (BMKG, USGS, EMSC, KAGGLE)
raw_payload	LONGTEXT	Full JSON/CSV row untuk auditing
load_timestamp	DATETIME	Waktu data dimuat ke sistem

B. Silver Layer (Cleaned & Validated)

Lapisan Silver menerima data dari Bronze dan menerapkan serangkaian aturan kualitas data (data quality rules). Data yang melewati validasi Silver dijamin telah memenuhi standar konsistensi dan kelengkapan minimum untuk analisis.

Transformasi kunci yang diterapkan di Silver Layer mencakup: parsing datetime ke timezone-aware UTC datetime, konversi semua field numerik ke tipe yang tepat, penghapusan record dengan null pada field kritis (datetime, latitude, longitude, magnitude), filter outlier berdasarkan rentang yang valid secara ilmiah, dan penandaan record yang dicurigai sebagai duplikat lintas sumber (kolom `is_duplicate_flag`).

C. Gold Layer (Curated & Presentation)

Lapisan Gold adalah lapisan tertinggi dalam Medallion Architecture yang berisi data paling bersih, terstruktur, dan siap dikonsumsi untuk analisis. Dalam SasimokGuard, Gold Layer diimplementasikan dalam bentuk Star Schema yang terdiri dari tabel fakta dan tabel dimensi. Hanya data dari Silver Layer yang telah lolos seluruh aturan validasi yang akan dipromosikan ke Gold Layer.

3.5 Pemodelan Dimensional (Star Schema)

A. Tabel Fakta — `fact_gempa`

Tabel `fact_gempa` adalah inti dari model dimensional SasimokGuard. Tabel ini menyimpan metrik kuantitatif dari setiap kejadian gempa bumi beserta foreign key ke seluruh tabel dimensi.

Kolom	Tipe Data	Keterangan
<code>id_fakta</code>	BIGINT PK	Surrogate key tabel fakta
<code>id_waktu</code>	INT FK	Referensi ke <code>dim_waktu</code>
<code>id_lokasi</code>	INT FK	Referensi ke <code>dim_lokasi</code>
<code>id_sumber</code>	INT FK	Referensi ke <code>dim_sumber</code>
<code>magnitudo</code>	DECIMAL(4,2)	Magnitudo gempa (skala Richter/Mw)
<code>kedalaman_km</code>	DECIMAL(7,2)	Kedalaman hiposenter dalam kilometer
<code>latitude</code>	DECIMAL(9,6)	Koordinat lintang epikenter
<code>longitude</code>	DECIMAL(9,6)	Koordinat bujur epikenter
<code>jml_kejadian</code>	INT	Jumlah kejadian (1 untuk event individual)
<code>load_ts</code>	DATETIME	Timestamp pemuatan ke Gold Layer

B. Tabel Dimensi

dim_waktu — Menyimpan atribut temporal dari setiap kejadian gempa, mencakup kolom: id_waktu (PK), datetime_utc, tahun, kuartal, bulan, nama_bulan, minggu_tahun, hari_dalam_minggu, nama_hari, jam, menit, dan is_weekend. Granularitas waktu pada level menit untuk mendukung analisis temporal yang presisi.

dim_lokasi — Menyimpan informasi geografis dan administratif dari lokasi gempa, mencakup: id_lokasi (PK), latitude_bin (dibulatkan ke 0.5 derajat untuk binning), longitude_bin, nama_provinsi, nama_pulau, zona_seismik (subduksi/transform/intraplate), dan kelas_wilayah (Sumatera, Jawa, Sulawesi, Papua, dsb.).

dim_sumber — Menyimpan metadata tentang sumber pencatat data gempa, mencakup: id_sumber (PK), kode_sumber (BMKG/USGS/EMSC/KAGGLE), nama_lengkap_sumber, negara_asal, tipe_sumber (government/international/research), dan url_sumber.

BAB IV

ANALISIS DATA DAN BUSINESS INTELLIGENCE

Analisis Business Intelligence pada SasimokGuard dilaksanakan menggunakan query SQL terhadap lapisan Gold (fact_gempa beserta tabel dimensi). Seluruh query dieksekusi pada database MySQL/PostgreSQL yang telah terisi data dari kedua pipeline ETL. Temuan pada setiap analisis disertai interpretasi domain seismologi untuk memberikan konteks yang bermakna.

4.1 Analisis Distribusi Magnitudo

Analisis distribusi magnitudo bertujuan untuk memahami sebaran intensitas kejadian gempa bumi dalam dataset SasimokGuard. Secara historis, frekuensi kejadian gempa mengikuti hubungan Gutenberg-Richter yang bersifat log-linier: semakin tinggi magnitudo, semakin jarang kejadian terjadi.

Klasifikasi kategori magnitudo yang digunakan dalam analisis ini mengacu pada skala BMKG:

Kategori	Rentang Magnitudo	Dampak Umum
Mikro	< 2.0	Tidak terasa, hanya terdeteksi instrumen
Minor	2.0 – 3.9	Terasa di dekat episenter, jarang merusak
Sedang	4.0 – 4.9	Terasa luas, kerusakan minor pada bangunan lemah
Moderat	5.0 – 5.9	Kerusakan signifikan pada bangunan tidak berstandar
Kuat	6.0 – 6.9	Kerusakan berat dalam radius 160 km
Mayor	7.0 – 7.9	Kerusakan serius, berpotensi tsunami
Hebat	≥ 8.0	Kerusakan total, berpotensi tsunami besar

Hasil analisis distribusi magnitudo pada dataset SasimokGuard menunjukkan bahwa mayoritas kejadian gempa tercatat (sekitar 70–80%) berada pada kategori Minor hingga Sedang (magnitudo 2.0–4.9). Temuan ini konsisten dengan karakteristik seismisitas Indonesia yang memiliki latar belakang noise seismik tinggi akibat aktivitas tektonik yang intens. Kejadian bermagnitudo tinggi (≥ 6.0) yang memiliki potensi destruktif

tinggi merupakan outlier yang meski jarang terjadi, menjadi fokus utama dalam analisis risiko.

Query SQL yang digunakan untuk analisis ini menggunakan fungsi CASE WHEN untuk mengkategorikan magnitudo, COUNT(*) untuk menghitung frekuensi per kategori, dan ROUND(... * 100.0 / SUM(*), 2) untuk menghitung persentase distribusi relatif.

4.2 Analisis Tren Aktivitas Seismik

Analisis tren aktivitas seismik bertujuan untuk mengidentifikasi pola temporal dalam frekuensi dan intensitas kejadian gempa dari waktu ke waktu. Tren ini sangat penting untuk pemahaman siklus seismik dan perencanaan kesiapsiagaan bencana jangka panjang.

Analisis tren dilakukan pada beberapa granularitas waktu: tahunan untuk mengidentifikasi tren dekade, bulanan untuk mendeteksi pola musiman (meski gempa tidak secara langsung dipengaruhi musim, pola ini relevan untuk aktivitas manusia seperti operasi tambang), dan mingguan untuk mendeteksi anomali jangka pendek.

Temuan signifikan dari analisis tren menunjukkan adanya periode peningkatan aktivitas seismik yang berkorelasi dengan peristiwa tektonik besar (foreshock/aftershock sequence). Analisis moving average 12 bulan (rolling window) pada frekuensi kejadian bulanan membantu menghaluskan fluktuasi jangka pendek dan mengekspos tren jangka panjang yang lebih bermakna secara ilmiah.

Dari perspektif data engineering, analisis tren ini juga berfungsi sebagai uji kewajaran (sanity check) untuk memverifikasi bahwa pipeline ETL beroperasi dengan benar — lonjakan atau penurunan tiba-tiba dalam volume data dapat mengindikasikan isu pada proses ekstraksi atau kualitas sumber data.

4.3 Analisis Frekuensi Kejadian Berdasarkan Wilayah

Analisis frekuensi berdasarkan wilayah merupakan salah satu analisis paling penting dari perspektif manajemen bencana. Peta konsentrasi seismik membantu

mengidentifikasi zona risiko tinggi yang memerlukan prioritas dalam perencanaan infrastruktur tahan gempa dan sistem peringatan dini.

Dalam SasimokGuard, analisis spasial dilakukan menggunakan atribut `dim_lokasi`, khususnya kolom `zona_seismik` dan `nama_provinsi`. Wilayah dikelompokkan berdasarkan zona tektonik utama Indonesia:

- Zona Subduksi Sumatera: Jalur pertemuan Lempeng Indo-Australia dan Lempeng Eurasia di sepanjang pantai barat Sumatera — secara historis merupakan zona paling aktif seismik di Indonesia.
- Zona Subduksi Jawa-Nusa Tenggara: Jalur subduksi di selatan Jawa hingga Nusa Tenggara, sumber kejadian gempa dangkal yang sering disertai tsunami.
- Zona Sulawesi: Persimpangan tiga lempeng yang menciptakan pola seismisitas sangat kompleks, termasuk sesar Palu-Koro yang menjadi penyebab gempa Palu 2018.
- Zona Papua: Zona kolisi antara Lempeng Australia dan mikrolempeng Papua, menghasilkan gempa dalam dan berenergi sangat tinggi.

Hasil analisis ini divisualisasikan dalam bentuk heatmap distribusi kejadian gempa yang dipetakan terhadap grid koordinat $1^{\circ} \times 1^{\circ}$, menggunakan agregasi `COUNT(*)` `GROUP BY` `latitude_bin`, `longitude_bin` dari tabel fakta melalui join ke `dim_lokasi`.

4.4 Analisis Hubungan Kedalaman (Depth) dan Magnitudo

Analisis korelasi antara kedalaman hiposenter dan magnitudo gempa merupakan dimensi analitik yang penting dalam pemahaman mekanisme sumber gempa. Dari perspektif seismologi, gempa dangkal (< 70 km) cenderung lebih destruktif karena energi seismik tidak mengalami atenuasi sebesar gempa dalam, meskipun magnitudonya mungkin lebih kecil.

SasimokGuard mengkategorikan kejadian gempa berdasarkan kedalaman sesuai klasifikasi internasional:

Kategori Kedalaman	Rentang (km)	Karakteristik Seismologis
Dangkal (Shallow)	0 – 70	Paling destruktif, potensi tsunami tinggi, sering terasa kuat di permukaan
Menengah (Intermediate)	70 – 300	Dampak permukaan lebih terlokalisir, energi menyebar lebih luas
Dalam (Deep)	300 – 700	Jarang merusak permukaan, terasa di area sangat luas dengan intensitas rendah

Analisis scatter plot antara depth dan magnitude (menggunakan binning kedalaman ke dalam interval 10 km) menunjukkan distribusi yang tidak seragam. Temuan khas pada data Indonesia adalah konsentrasi kejadian bermagnitudo tinggi ($M > 6.0$) pada kedalaman dangkal (0–50 km) di sepanjang zona subduksi, yang konsisten dengan mekanisme sesar naik (thrust fault) pada batas lempeng konvergen.

Query SQL untuk analisis ini memanfaatkan fungsi CORR() (untuk database yang mendukung, seperti PostgreSQL) atau kalkulasi manual Pearson correlation menggunakan formula matematis dalam SQL untuk mengukur kekuatan hubungan statistik antara depth dan magnitude.

4.5 Komparasi Volume Data Berdasarkan Sumber Pencatat

Analisis komparasi sumber data bertujuan untuk memahami karakteristik dan keterwakilan masing-masing sumber dalam dataset SasimokGuard. Perbedaan volume dan cakupan antar sumber mencerminkan perbedaan dalam sensitivitas jaringan seismograf, cakupan geografis, dan kebijakan pelaporan masing-masing lembaga.

Sumber	Fokus Cakupan	Kekuatan	Keterbatasan
BMKG	Indonesia & sekitarnya	Data paling komprehensif untuk Indonesia, waktu respons cepat	Cakupan terbatas di luar wilayah Indonesia
USGS	Global	Standar referensi internasional, histori data panjang	Underreporting untuk gempa kecil di luar AS
EMSC	Global (fokus Eropa-Mediterrania)	Data real-time, validasi komunitas	Coverage Indonesia lebih terbatas
Kaggle/BMKG CSV	Indonesia (historis)	Data historis jangka panjang, cocok untuk tren analisis	Data statis, tidak diperbarui otomatis

Analisis tumpang tindih antar sumber (source overlap analysis) menggunakan proximity matching menunjukkan bahwa BMKG dan USGS memiliki tingkat konsistensi pelaporan yang tinggi untuk kejadian bermagnitudo ≥ 5.0 , namun BMKG secara konsisten melaporkan lebih banyak kejadian kecil ($M < 4.0$) di wilayah Indonesia. Hal ini mencerminkan keunggulan jaringan seismograf regional BMKG yang tersebar luas di seluruh kepulauan Indonesia.

Temuan dari analisis sumber ini memiliki implikasi penting dalam strategi pipeline ETL: untuk analisis historis jangka panjang, Kaggle/BMKG CSV menjadi sumber utama; untuk monitoring real-time, ketiga API digunakan secara paralel dengan strategi deduplikasi lintas sumber yang telah diimplementasikan dalam Pipeline 2.

BAB V

PENUTUP

5.1 Kesimpulan

Berdasarkan seluruh tahapan perancangan, implementasi, dan analisis yang telah dilaksanakan dalam proyek SasimokGuard, dapat ditarik beberapa kesimpulan utama sebagai berikut:

- 1 SasimokGuard berhasil membangun sistem data warehouse terintegrasi untuk data seismik Indonesia dengan mengimplementasikan pendekatan Dual-Pipeline yang efektif memisahkan pemrosesan data historis (Pipeline 1 via Kaggle/BMKG CSV) dan data real-time (Pipeline 2 via API BMKG, USGS, EMSC). Pemisahan pipeline ini terbukti meningkatkan fleksibilitas, kemudahan pemeliharaan, dan efisiensi pemrosesan secara keseluruhan.
- 2 Penerapan Medallion Architecture tiga lapis (Bronze, Silver, Gold) berhasil menjamin kualitas dan keterlacakan data di setiap tahapan pemrosesan. Lapisan Bronze menyediakan arsip data mentah yang lengkap; lapisan Silver memastikan konsistensi dan kebersihan data melalui serangkaian aturan validasi; lapisan Gold menyajikan data yang siap analisis dalam model dimensional yang optimal.
- 3 Pemodelan dimensional berbasis Star Schema dengan tabel fakta fact_gempa dan tiga tabel dimensi (dim_waktu, dim_lokasi, dim_sumber) terbukti efektif mendukung berbagai jenis query analitik kompleks dengan performa yang baik. Desain skema ini memungkinkan analisis multi-dimensi data seismik secara fleksibel dan intuitif.
- 4 Analisis Business Intelligence yang dilakukan terhadap data Gold menghasilkan wawasan bermakna: (a) distribusi magnitudo mengikuti pola Gutenberg-Richter dengan dominasi kejadian Minor-Sedang; (b) tren aktivitas seismik menunjukkan korelasi kuat dengan peristiwa tektonik besar melalui pola aftershock sequence; (c) zona Sumatera dan Papua Barat teridentifikasi sebagai wilayah dengan frekuensi seismik tertinggi; (d) gempa dangkal (< 70 km)

mendominasi kejadian destruktif; (e) BMKG merupakan sumber paling komprehensif untuk cakupan wilayah Indonesia.

- 5 Implementasi strategi deduplikasi lintas sumber berbasis proximity matching berhasil mengurangi redundansi data secara signifikan sambil mempertahankan kelengkapan informasi dari perspektif multi-lembaga pencatat.

5.2 Saran

Guna meningkatkan kualitas dan kapabilitas sistem SasimokGuard ke depannya, berikut beberapa saran pengembangan yang direkomendasikan:

Pengembangan Teknis

- Orkestrasi Pipeline Otomatis: Mengintegrasikan pipeline ETL dengan orkestrator workflow seperti Apache Airflow atau Prefect untuk penjadwalan otomatis, monitoring, dan alerting ketika terjadi kegagalan pipeline.
- Peningkatan Infrastruktur Data: Mempertimbangkan migrasi dari MySQL/PostgreSQL ke platform data lakehouse (Apache Hudi atau Delta Lake di atas cloud storage) untuk penanganan volume data yang lebih besar dan dukungan time-travel queries.
- Integrasi Data Tambahan: Menambahkan sumber data komplementer seperti data topografi DEMNAS, data penduduk BPS per kecamatan, dan data infrastruktur kritis untuk analisis risiko bencana yang lebih komprehensif.
- Real-Time Streaming: Mengimplementasikan arsitektur streaming menggunakan Apache Kafka dan Apache Flink untuk mempersingkat latency pemrosesan data dari menit menjadi detik.

Peningkatan Analisis

- Machine Learning Integration: Mengintegrasikan model prediktif (misalnya, LSTM untuk prediksi deret waktu seismik atau model klasifikasi risiko wilayah) yang dikembangkan di atas Gold Layer untuk meningkatkan kapabilitas analitik.

- **Dashboard Interaktif:** Membangun dashboard Business Intelligence menggunakan Apache Superset, Grafana, atau Metabase yang terhubung langsung ke lapisan Gold untuk visualisasi data seismik secara real-time.
- **Analisis Jaringan Seismik:** Mengembangkan analisis klasterisasi spasial-temporal (ST-DBSCAN) untuk mengidentifikasi swarm seismik dan sekuens foreshock-mainshock-aftershock secara otomatis.

Kolaborasi dan Diseminasi

- **Open Data Publishing:** Mempertimbangkan publikasi dataset Gold Layer yang telah dikurasi sebagai open dataset di platform Kaggle atau GitHub untuk mendukung komunitas riset seismologi dan data science Indonesia.
- **Kolaborasi Kelembagaan:** Mengeksplorasi potensi kerjasama dengan BMKG, BPBD, dan BNPB untuk validasi model analisis dan pemanfaatan sistem dalam konteks operasional penanggulangan bencana.

LAMPIRAN

Git Hub: <https://github.com/GhenAyari/UTS-BussinesIntelligence>

Gcolab Api:

https://colab.research.google.com/drive/1wXfwk2O_Tew6N_IU9XsbOTWoqLAqU_vt#scrollTo=0kE8HT3QATPW

Gcolab Kaggle:

<https://colab.research.google.com/drive/1a8lqDQO9aGkeS4tibY6kWKLGm6XWmTmt>